Вебинар 4. Домашнее задание

Само домашнее задание нахожится в конце ноутбука

In [284]:

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
%matplotlib inline
# Для работы с матрицами
from scipy.sparse import csr_matrix
# Матричная факторизация
from implicit.als import AlternatingLeastSquares
from implicit.nearest_neighbours import ItemItemRecommender # нужен для одного трюка
from implicit.nearest_neighbours import bm25_weight, tfidf_weight
# Функции из 1-ого вебинара
import os, sys
module_path = os.path.abspath(os.path.join(os.pardir))
if module_path not in sys.path:
    sys.path.append(module_path)
# from src.metrics import precision_at_k, recall_at_k
# from src.utils import prefilter_items
from metrics import precision_at_k, recall_at_k
from utils import prefilter items
```

In [285]:

Out[285]:

	user_id	basket_id	day	item_id	quantity	sales_value	store_id	retail_disc	trans_time
0	2375	26984851472	1	1004906	1	1.39	364	-0.60	1631
1	2375	26984851472	1	1033142	1	0.82	364	0.00	1631
2	2375	26984851472	1	1036325	1	0.99	364	-0.30	1631
3	2375	26984851472	1	1082185	1	1.21	364	0.00	1631
4	2375	26984851472	1	8160430	1	1.50	364	-0.39	1631
4									•

In [286]:

```
data_test['week_no'].max()
```

Out[286]:

102

In [287]:

```
item_features = pd.read_csv('../data/product.csv')
item_features.columns = [col.lower() for col in item_features.columns]
item_features.rename(columns={'product_id': 'item_id'}, inplace=True)
item_features.head()
```

Out[287]:

	item_id	manufacturer	department	brand	commodity_desc	sub_commodity_desc	curr_
0	25671	2	GROCERY	National	FRZN ICE	ICE - CRUSHED/CUBED	_
1	26081	2	MISC. TRANS.	National	NO COMMODITY DESCRIPTION	NO SUBCOMMODITY DESCRIPTION	
2	26093	69	PASTRY	Private	BREAD	BREAD:ITALIAN/FRENCH	
3	26190	69	GROCERY	Private	FRUIT - SHELF STABLE	APPLE SAUCE	
4	26355	69	GROCERY	Private	COOKIES/CONES	SPECIALTY COOKIES	

•

In [288]:

data.shape

Out[288]:

(2595732, 12)

In [289]:

```
item_features.shape
```

Out[289]:

(92353, 7)

In [290]:

```
result = data_test.groupby('user_id')['item_id'].unique().reset_index()
result.columns=['user_id', 'actual']
result.head(2)
```

Out[290]:

	user_id	actual
0	1	[879517, 934369, 1115576, 1124029, 5572301, 65
1	3	[823704, 834117, 840244, 913785, 917816, 93870

```
In [291]:
```

data_test

Out[291]:

	user_id	basket_id	day	item_id	quantity	sales_value	store_id	retail_disc	tran
2479936	790	41931228451	685	822989	1	7.29	31782	0.00	
2479937	790	41931228451	685	849003	1	2.59	31782	0.00	
2479938	790	41931228451	685	884731	1	2.19	31782	0.00	
2479939	790	41931228451	685	920109	1	3.08	31782	0.00	
2479940	790	41931228451	685	976998	3	1.77	31782	0.00	
2595727	1598	42305362535	711	92130	1	0.99	3228	0.00	
2595728	1598	42305362535	711	114102	1	8.89	3228	0.00	
2595729	1598	42305362535	711	133449	1	6.99	3228	0.00	
2595730	1598	42305362535	711	6923644	1	4.50	3228	-0.49	
2595731	1598	42305362535	711	14055192	1	6.99	3228	0.00	

110194 rows × 12 columns

In [292]:

```
data_train['item_id'].nunique()
```

Out[292]:

90386

In [293]:

```
data_train.shape
```

Out[293]:

(2485538, 12)

In [294]:

```
data_train = data_train[:10000]
```

In [295]:

```
data_train.shape
```

Out[295]:

(10000, 12)

In [296]:

```
n_items_before = data_train['item_id'].nunique()

# data_train = prefilter_items(data_train, item_features, take_n_popular=5000)

n_items_after = data_train['item_id'].nunique()

print('Decreased # items from {} to {}'.format(n_items_before, n_items_after))
```

Decreased # items from 5913 to 5913

In [297]:

Out[297]:

item_id	34198	39592	40885	50905	70302	72816	78888	108623	113154	122280	•••	98376
user_id												
14	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0		(
25	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0		(
34	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0		(
46	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0		(
51	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0		(

5 rows × 5913 columns

```
→
```

In [298]:

```
userids = user_item_matrix.index.values
itemids = user_item_matrix.columns.values

matrix_userids = np.arange(len(userids))
matrix_itemids = np.arange(len(itemids))

id_to_itemid = dict(zip(matrix_itemids, itemids))
id_to_userid = dict(zip(matrix_userids, userids))

itemid_to_id = dict(zip(itemids, matrix_itemids))
userid_to_id = dict(zip(userids, matrix_userids))
```

```
In [299]:
userid_to_id[14]
Out[299]:
0
In [300]:
user_item_matrix = bm25_weight(user_item_matrix.T).T # Применяется к item-user матрице!
In [301]:
%%time
model = AlternatingLeastSquares(factors=20,
                                 regularization=0.001,
                                 iterations=15,
                                 calculate_training_loss=True,
                                 num_threads=4)
model.fit(csr_matrix(user_item_matrix).T.tocsr(), # Ha βxo∂ item-user matrix
          show_progress=True)
               | 0/15 [00:00<?, ?it/s]
  0%|
Wall time: 3.28 s
In [302]:
userid_to_id[25]
Out[302]:
1
In [ ]:
In [303]:
userid = 1
user_items = user_item_matrix
N = 5
```

In [304]:

In [305]:

```
get_recommendations(25, model, user_item_matrix)
```

Out[305]:

	item	name
0	903567	[CANDY - PACKAGED]
1	1130666	[SEAFOOD - FROZEN]
2	869728	[MISC. DAIRY]
3	948756	[BAKING MIXES]
4	973374	[ONIONS]

In [306]:

```
data.head()
```

Out[306]:

	user_id	basket_id	day	item_id	quantity	sales_value	store_id	retail_disc	trans_time
0	2375	26984851472	1	1004906	1	1.39	364	-0.60	1631
1	2375	26984851472	1	1033142	1	0.82	364	0.00	1631
2	2375	26984851472	1	1036325	1	0.99	364	-0.30	1631
3	2375	26984851472	1	1082185	1	1.21	364	0.00	1631
4	2375	26984851472	1	8160430	1	1.50	364	-0.39	1631
4									>

In []:

In [307]:

```
b = [13,27,38,54,65]
c = ['a', 'b', 'c', 'd', 'e']
f = [0,1,1,1,0]
p = [13, 27]
```

In [308]:

```
a = pd.DataFrame([b,c,f])
a = a.T
a.columns = ['b', 'c', 'f']
a
```

Out[308]:

```
b c f0 13 a 01 27 b 1
```

-
- **2** 38 c 1
- **3** 54 d 1
- **4** 65 e 0

In [309]:

```
a = a[(a['b'] > 13) & (a['b']<54)]
a
```

Out[309]:

```
b c f

1 27 b 1
```

2 38 c 1

In [310]:

```
if 'f' in a:
    print('yes')
else:
    print('no')
```

yes

In [311]:

```
a.loc[(a['c'] == 'b') | (a['b']> 13)]
Out[311]:
    b c f
2 38 c 1
In [197]:
def prefilter_items(data, n_top= 5000):
   # Уберем самые популярные товары (их и так купят)
   if 'quantity' in data.columns:
        popularity = data.groupby('item_id')['quantity'].sum().reset_index()
        popularity.rename(columns={'quantity': 'n_sold'}, inplace=True)
        top_n = popularity.sort_values('n_sold', ascending=False).head(n_top).item_id.tolis
        data = data.loc[~data['item_id'].isin([i for i in top_n])]
   # Уберем товары, которые не продавались за последние 12 месяцев
        week_53 = list(range(53))
        data = data.loc[~data['quantity'].isin([0]) & ~data['week_no'].isin([i for i in wee
   # Уберем слишком дешевые товары (на них не заработаем). 1 покупка из рассылок стоит 60
   # Уберем слишком дорогие товары
   elif 'price' in data.columns:
        data = data[(data['price'] > 61) & (data['price'] < 5000)]</pre>
   # Уберем не интересные для рекоммендаций категории (department)
   # мясо и так купят, медикаменты можно только по рекомендации врача, 'MISC. TRANS.'- не
   else:
        cat_prod = ['MISC. TRANS.', 'MEAT-PCKGD', 'MEAT', 'DRUG GM']
        data = data.loc[~data['department'].isin([i for i in cat prod])]
   return data
def postfilter items(user id, recommednations):
   pass
In [312]:
data.shape
Out[312]:
(2595732, 12)
```

```
In [199]:
data = prefilter_items(data)
In [200]:
data.shape
Out[200]:
(507035, 12)
In [201]:
len(item_features['department'].unique())
Out[201]:
44
In [202]:
item_features = prefilter_items(item_features)
In [203]:
len(item_features['department'].unique())
Out[203]:
40
In [ ]:
```

get_similar_items_recommendation

```
In [313]:
```

```
from collections import Counter
```

In [314]:

```
result['actual_top_5'] = [[element for element,count in Counter(i).most_common(3)] for i in
result.drop('actual',1, inplace=True)
result.head()
```

Out[314]:

	user_id	actual_top_5
0	1	[879517, 934369, 1115576]
1	3	[823704, 834117, 840244]
2	5	[913077, 1118028, 1386668]
3	6	[825541, 859676, 999318]
4	7	[929248, 948622, 1013572]

In [315]:

```
#create Series
s = result.set_index('user_id')['actual_top_5']
#create DataFrame, reshape by stack and conver MultiIndex to columns
df = pd.DataFrame(s.values.tolist(), index=s.index).stack().reset_index()
df.columns= ['user_id','i','actual_top_5']
```

In [316]:

```
df_top = df.groupby(['user_id','actual_top_5']).size().reset_index(name='count')
# res = result.groupby(['user_id', 'actual_top_5']).size()#.reset_index(name='count')
```

In [317]:

```
df_top['actual_top_5']=df['actual_top_5'].astype('int')
```

In [318]:

```
df_top.drop('count',1, inplace= True)
```

In [319]:

```
df_top.rename(columns={'actual_top_5': 'item_id'}, inplace=True)
```

In [325]:

```
df_top[:7]
```

Out[325]:

	user_id	item_id
0	1	879517
1	1	934369
2	1	1115576
3	3	823704
4	3	834117
5	3	840244
6	5	913077

In [321]:

```
res_top = data.merge(df_top, on=["item_id", 'user_id'], how= 'right')
```

In [324]:

```
res_top.loc[res_top['user_id'] == 3, 'item_id']
```

Out[324]:

15 823704

16 834117

17 840244

18 840244

Name: item_id, dtype: int64

In [327]:

```
res_top.head()
```

Out[327]:

	user_id	basket_id	day	item_id	quantity	sales_value	store_id	retail_disc	trans_time
0	1	41970711432	687	879517	1	3.99	436	-0.50	1754
1	1	28282581446	108	934369	1	1.50	436	-0.69	1513
2	1	30578772112	235	934369	1	1.39	436	-0.80	1705
3	1	30700731221	246	934369	1	1.39	436	-0.80	1143
4	1	31172831466	282	934369	1	1.59	436	-0.60	1528
4									•

In [328]:

Out[328]:

item_id	27658	28268	36055	36608	40694	43020	45720	46967	57390	66746	 17900917
user_id											
1	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	 0.0
3	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	 0.0
5	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	 0.0
6	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	 0.0
7	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	 0.0

5 rows × 3187 columns

←

In [329]:

```
userids = user_item_matrix.index.values
itemids = user_item_matrix.columns.values

matrix_userids = np.arange(len(userids))
matrix_itemids = np.arange(len(itemids))

id_to_itemid = dict(zip(matrix_itemids, itemids))
id_to_userid = dict(zip(matrix_userids, userids))

itemid_to_id = dict(zip(itemids, matrix_itemids))
userid_to_id = dict(zip(userids, matrix_userids))
```

In [330]:

```
user_item_matrix = bm25_weight(user_item_matrix.T).T # Применяется к item-user матрице !
```

In [331]:

wall time: 2.9/ S

In []:

In [332]:

```
def get_similar_items_recommendation(user, model,sparse_user_item, N=5):
    """Рекомендуем товары, похожие на топ-N купленных юзером товаров"""
   res = [id_to_itemid[rec[0]] for rec in
                    model.recommend(userid=userid_to_id[user],
                                    user_items=sparse_user_item,
                                                                   # на вход user-item matr
                                    N=N.
                                    filter_already_liked_items=False,
                                      filter_items=[itemid_to_id[1005609]], # !!!
#
                                    recalculate_user=True)]
   res_2 = [list(item_features.loc[item_features['item_id']== i, 'sub_commodity_desc']) fo
   result = pd.DataFrame(list(zip(res, res_2)), columns= ('item', 'name'))
   return result
   # your_code
   return res
```

In [337]:

```
get_similar_items_recommendation(3, model, user_item_matrix)
```

Out[337]:

name	item	
[ROLLS - PORK]	823704	0
[BUTTER]	872137	1
[FACIAL TISSUE & PAPER HANDKE]	840227	2
[CANDY REFRIGERATED]	909497	3
[SW GDS:DONUTS]	824180	4

```
In [338]:
840244
item_features[item_features['item_id']== 823704]
Out[338]:
                                                                    sub_commodity_des
      item_id manufacturer
                           department
                                       brand
                                                    commodity_desc
                               MEAT-
                                                        BREAKFAST
6354
     823704
                     2082
                                                                          ROLLS - POR
                                      National
                                              SAUSAGE/SANDWICHES
                              PCKGD
In [ ]:
```

Домашнее задание

- 1. Перенесите метрики в модуль metrics.py (убедится что они там)
- 2. Перенесите функцию prefilter items в модуль utils.py
- 3. Создайте модуль recommenders.py. Напищите код для класса ниже (задание обсуждали на вебинаре, для первой функции практически сделали) и положите его в recommenders.py
- 4. Проверьте, что все модули корректно импортируются

In [339]:

```
import pandas as pd
import numpy as np
# Для работы с матрицами
from scipy.sparse import csr_matrix
# Матричная факторизация
from implicit.als import AlternatingLeastSquares
from implicit.nearest_neighbours import ItemItemRecommender # нужен для одного трюка
from implicit.nearest neighbours import bm25 weight, tfidf weight
class MainRecommender:
    """Рекоммендации, которые можно получить из ALS
   Input
   user_item_matrix: pd.DataFrame
        Матрица взаимодействий user-item
   def __init__(self, data, weighting=True):
        # your_code. Это не обязательная часть. Но если вам удобно что-либо посчитать тут -
        self.user_item_matrix = self.prepare_matrix(data) # pd.DataFrame
        self.id_to_itemid, self.id_to_userid, self.itemid_to_id, self.userid_to_id = prepar
        if weighting:
            self.user_item_matrix = bm25_weight(self.user_item_matrix.T).T
        self.model = self.fit(self.user_item_matrix)
        self.own_recommender = self.fit_own_recommender(self.user_item_matrix)
   @staticmethod
   def prepare_matrix(data: pd.DataFrame):
        # your_code
        user_item_matrix = pd.pivot_table(data,
                                  index='user_id', columns='item_id',
                                  values='quantity', # Можно пробовать другие варианты
                                  aggfunc='count',
                                  fill value=0
        user item matrix = user item matrix.astype(float) # необходимый тип матрицы для imp
        return user_item_matrix
   @staticmethod
   def prepare dicts(user item matrix):
        """Подготавливает вспомогательные словари"""
        userids = user_item_matrix.index.values
        itemids = user_item_matrix.columns.values
        matrix userids = np.arange(len(userids))
        matrix itemids = np.arange(len(itemids))
```

```
id_to_itemid = dict(zip(matrix_itemids, itemids))
    id_to_userid = dict(zip(matrix_userids, userids))
    itemid to id = dict(zip(itemids, matrix itemids))
    userid_to_id = dict(zip(userids, matrix_userids))
    return id_to_itemid, id_to_userid, itemid_to_id, userid_to_id
@staticmethod
def fit_own_recommender(user_item_matrix):
    """Обучает модель, которая рекомендует товары, среди товаров, купленных юзером"""
    own_recommender = ItemItemRecommender(K=1, num_threads=4)
    own recommender.fit(csr matrix(user item matrix).T.tocsr())
    return own_recommender
@staticmethod
def fit(user_item_matrix, factors=20, regularization=0.001, iterations=15, num_threads=
    """Обучает ALS"""
    model = AlternatingLeastSquares(factors=factors,
                                         regularization=regularization,
                                         iterations=iterations,
                                         num_threads=num_threads)
    model.fit(csr matrix(self.user item matrix).T.tocsr())
    return model
def get_similar_items_recommendation(self, user, N=5):
    """Рекомендуем товары, похожие на топ-N купленных юзером товаров"""
    # your code
    # Практически полностью реализовали на прошлом вебинаре
    assert len(res) == N, 'Количество рекомендаций != {}'.format(N)
    return res
def get_similar_users_recommendation(self, user, N=5):
    """Рекомендуем топ-N товаров, среди купленных похожими юзерами"""
    # your code
    assert len(res) == N, 'Количество рекомендаций != {}'.format(N)
    return res
```

Проверка, что все работает

In [340]:

from metrics import precision_at_k, recall_at_k
from utils import prefilter_items
from recommenders import MainRecommender

In []:			